

【封面页请按学校模板单独填写】

基于大语言模型推理优化的城市动态路径规划方法研究

中文摘要

决策与规划是自动驾驶系统的核心环节，其性能直接影响车辆的安全性、通行效率与系统鲁棒性。在城市复杂路网中，交通约束通常以自然语言形式出现，例如道路拥堵、临时封闭、方向性限制和时段性切换等。传统路径规划方法虽然能够在给定确定性边权后快速求解最优路径，但缺乏对自然语言动态交通约束的直接解析能力。近年来，大语言模型在复杂语义理解方面表现突出，但当其被直接用于大规模路网的全量边权生成时，往往受到长序列输出截断、注意力稀释和结构化格式不稳定等问题的影响，导致关键异常边漏检和路径规划失效。

针对上述问题，本文提出一种面向城市动态路径规划的大语言模型推理优化方法，以时空依赖增强输入、稀疏异常语义锚点提取、经典搜索和 SUMO 闭环验证为主线：首先，将道路名、方向、影响范围、拥堵等级、时间标签、传播范围和冲突状态等要素从自然语言描述中提取为结构化字段，以增强模型对时空依赖的显式感知；其次，提出稀疏语义锚点输出范式，将大模型的任务从全网密集边权生成重构为关键异常边识别，仅输出偏离正常状态的局部异常锚点；最后，将解析得到的边权输入经典搜索算法，并在 SUMO 微观交通仿真环境中进行闭环验证。

实验结果表明，当前冻结的主方法 Sparse-LoRA-v2 (stage4_fix) 在 completion-aware SUMO 6 场景固定协议下取得了稳健的闭环表现：其平均行程时间为 1257.33 s，与规则驱动基线 Rule-A* (1257.12 s) 基本持平；Completion Rate 为 83.3%，Truncated Runs 为 1。冻结主表同时报告完成率与截断次数，避免将 evaluation horizon 截断时间误解释为真实到达时间。在结构化时空输入消融实验中，去除时空增强后平均行程时间上升至 542.33 s (+6.1%)，约束遵守率下降至 50.98%，说明结构化时空字段注入能够显著提升约束解析质量。在抗截断测试中，稀疏输出方法在 noisy_long 场景中截断率为 0%，而全量输出基线截断率达 100%，验证了稀疏语义锚点设计的有效性。

本文的主要贡献体现在三个方面：（1）提出面向城市动态路径规划的结构化时空输入机制，将隐式自然语言交通约束转换为显式时空语义字段；

(2) 提出稀疏语义锚点输出范式，将大模型从全量边权生成器重构为关键异常提取器，从根本上缓解长序列截断与解析失稳问题；（3）构建严格评估协议与 SUMO 闭环验证框架，以 changed-edge 召回、NO_ANCHOR 失败等指标替代宽松的平均 MAE 口径，提高了实验结论的可信度与可复现性。

需要指出的是，主表结果与消融实验来自不同实验协议：前者基于 Live SUMO 6 场景固定协议（seeds 101-505），后者基于消融场景协议均值，两组数值分别支撑不同结论，不作直接横向比较。

关键词：自动驾驶；路径规划；大语言模型；稀疏语义锚点；时空依赖增强；严格评估；SUMO 仿真

ABSTRACT

Decision-making and path planning are central components of autonomous driving systems, directly affecting safety, efficiency, and robustness. In urban road networks, dynamic traffic constraints are often expressed in natural language, including congestion, temporary closure, directional restrictions, and time-dependent state transitions. Traditional planning algorithms can efficiently compute optimal routes once reliable edge costs are given, but they do not directly parse such semantic constraints. Large language models have recently shown strong capabilities in semantic understanding; however, when used to generate dense edge weights for large road networks, they often suffer from long-output truncation, attention dilution, and formatting failures, which cause critical abnormal edges to be missed.

To address these issues, this thesis proposes an inference optimization framework for dynamic path planning in urban road networks. The framework follows the pipeline of structured spatiotemporal-enhanced input, sparse abnormal semantic anchor extraction, classical graph search, and SUMO closed-loop validation. Natural-language traffic descriptions are first converted into structured fields (ROAD, DIR, RANGE, LEVEL, TIME, PROPAGATION, CONFLICT) for explicit spatiotemporal modeling. A sparse semantic anchor output paradigm then reformulates the task from dense full-graph edge-weight prediction to key abnormal-edge identification. The parsed edge costs are finally passed to classical search methods and evaluated in SUMO under a fixed multi-scene protocol.

Experimental results show that the frozen main model Sparse-LoRA-v2 (stage4_fix) achieves a travel time of 1257.33 s under the completion-aware SUMO 6-scene fixed protocol, essentially matching Rule-A* (1257.12 s). Its Completion Rate is 83.3% with one Truncated Run, and the frozen table reports completion status explicitly to avoid interpreting evaluation-horizon truncation as real arrival time. In the input ablation study, removing spatiotemporal enhancement increases travel

time to 542.33 s and reduces compliance to 50.98%, under the ablation protocol rather than the main live-SUMO protocol. In anti-truncation tests, the sparse-output formulation achieves 0% truncation rate under `noisy_long` pressure, versus 100% for dense-output baselines.

It should be noted that the main table and the ablation study use different experimental protocols: the former is based on the Live SUMO 6-scene fixed protocol (seeds 101-505), and the latter on ablation-scenario averages. The two sets of numbers support different conclusions and are not directly comparable.

Key words: autonomous driving; path planning; large language model; sparse semantic anchors; spatiotemporal enhancement; strict evaluation; SUMO simulation

目录

中文摘要.....	2
ABSTRACT.....	4
目.....	6
录.....	7
第1章 绪论.....	8
1.1 研究背景与意义.....	8
1.2 国内外研究现状.....	9
1.2.1 经典路径规划与强化学习方法.....	9
1.2.2 图神经网络与交通时空建模.....	9
1.2.3 大语言模型与结构化输出.....	10
1.2.4 现有工作的不足.....	10
1.3 研究问题与本文贡献.....	11
1.4 论文结构安排.....	11
第2章 方法设计.....	12
2.1 问题定义与数学形式化.....	12
2.1.1 路网与任务形式化.....	12
2.1.2 结构化输入与边权映射.....	12
2.1.3 路径规划目标.....	12
2.1.4 LoRA 参数高效微调.....	13
2.1.5 评估指标的形式化定义.....	13
2.2 结构化时空增强输入.....	13
2.2.1 设计动机.....	14
2.2.2 字段定义.....	14
2.2.3 输入模板.....	14
2.3 稀疏语义锚点输出范式.....	15
2.3.1 从全量边权生成到异常锚点提取.....	15
2.3.2 结构化输出设计视角.....	15
2.4 经典搜索与基线设计.....	15
2.4.1 路由求解.....	15
2.4.2 Rule-A*基线设计与对比公平性说明.....	16
2.5 图补全模块的定位.....	17
2.6 严格评估协议与 SUMO 闭环.....	17
2.6.1 严格评估设计动机.....	17
2.6.2 SUMO 闭环实验设置.....	17
第3章 实验设计、结果与分析.....	19
3.1 实验目标与研究问题.....	19
3.2 实验平台、数据集与统一协议.....	19

3.2.1 实验平台.....	19
3.2.2 训练数据集构建.....	19
3.3 对比方法与实现细节.....	20
3.3.1 主方法：Sparse-LoRA-v2 / stage4_fix.....	20
3.3.2 基线方法汇总.....	21
3.4 评价指标.....	22
3.5 主结果：SUMO 闭环性能比较.....	23
3.6 SUMO 交通运行补充指标.....	25
3.7 消融实验：时空增强输入的贡献.....	28
3.8 抗截断与严格评估分析.....	28
3.8.1 抗截断实验.....	28
3.8.2 严格评估的价值.....	29
3.8.3 复杂场景严格评估细分.....	30
3.8.4 val_special 场景细分与 val_anti_truncation 结果.....	30
3.8.5 val_normal 按输入长度分桶分析.....	30
3.9 误差分析与消融实验扩展.....	32
3.9.1 主方法 Baseline 完整性能分解.....	32
3.9.2 推理时指令注入实验（DIR_RULE）.....	33
3.9.3 错误类型系统分析.....	34
3.9.4 GAT 图补全与 RL 基线（探索性）.....	35
3.10 讨论与局限性.....	35
3.10.1 已经成立的结论.....	35
3.10.2 主要局限性.....	36
3.11 本章小结.....	36
第4章 总结与展望.....	38
4.1 全文总结.....	38
4.2 后续工作展望.....	38
参考文献.....	40
附录.....	41
附录 A1 Qwen-LoRA 与 R1-LoRA 消融场景结果.....	41
附录 A2 GAT 图补全探索性实验详细结果.....	41
附录 A3 RL 基线覆盖性说明.....	42
附录 A4 simple_local 场景严格评估失败分析.....	42
附录 A5 Stage4 定向修复迭代失败记录.....	42
攻读学位期间学术论文和科研成果目录.....	44
致谢.....	45

第1章 绪论

1.1 研究背景与意义

城市自动驾驶系统需要在复杂路网中对动态交通事件进行快速、可靠的路径决策。与静态地图导航不同，实际交通约束具有明显的时变性、方向性和语义性：同一条道路可能在不同时间段表现出不同拥堵状态，不同方向的交通流可能具有不对称性，且大量约束以自然语言方式出现，例如早高峰黄河路向东严重拥堵、事故排队外溢至花园路、09:30 后恢复正常等。

传统路径规划算法如 A*、Dijkstra 和 Bellman-Ford 在确定性图权重条件下能够高效求解最短路，但它们并不直接具备从自然语言交通描述中抽取约束并转化为可计算边权的能力[1]。近年来，大语言模型（LLM）在语义理解、信息抽取与复杂推理任务中表现出较强潜力，因此被逐步引入规划、导航与交通场景。然而，LLM 虽擅长全局语义理解，但在精细的空间—时间推理和可验证结构化输出上仍然存在明显不足[7]。

本文研究的核心问题在于：如何让小参数量的微调 LLM 在自然语言交通约束理解任务中，既能稳定输出可解析的结构化结果，又能在 SUMO 闭环仿真中产生真实有效的行程时间改善？这一问题不是简单地将 LLM 接到路径规划前面，而是涉及任务接口设计、输出空间重构和评估协议标准化等多个层面。

1.2 国内外研究现状

1.2.1 经典路径规划与强化学习方法

传统路径规划主要依赖图搜索与启发式算法。A*算法通过启发函数在最优性与效率之间取得平衡，是导航与机器人规划中的经典方法；Dijkstra 算法适用于一般非负图的单源最短路求解；Bellman-Ford 算法则支持含负权图，

可作为正确性对照基准[1]。这些算法在确定性环境下表现突出，但通常假设环境状态已经数值化，对自然语言形式的动态交通约束缺乏直接建模能力。

强化学习方面，DQN 通过深度网络逼近动作价值函数，实现了高维状态下的端到端控制[12]；PPO 则通过剪切目标函数在稳定性与实现复杂度之间取得良好折中[13]。本文也实现了 DQN 和 PPO 的覆盖性基线（简化 5×5 网格环境），但由于环境与 SUMO 主协议不匹配，其结果仅作为附录参考。

1.2.2 图神经网络与交通时空建模

交通预测领域的代表性图方法形成了较成熟的研究脉络。DCRNN 将交通流建模为有向图上的扩散过程，强调方向性空间依赖与时间演化[3]；STGCN 用纯卷积结构联合建模空间和时间依赖[4]；Graph WaveNet 使用自适应依赖矩阵学习隐藏空间联系[5]；AGCRN 则进一步强调节点特异性与数据驱动图生成[6]。上述工作共同表明，交通系统中显式建模时空依赖和拓扑关系对预测质量至关重要。

然而，这些方法的输入通常是数值型传感器序列，不直接面向自然语言交通事件，也不解决从语义描述到可计算路由权重的映射问题。本文借鉴其时空依赖建模思想，将时间标签、传播范围等信息结构化后注入 LLM 输入，以弥补语义理解与图结构之间的接口断层。近期工作 ST-LLM+ 已将图增强时空表示与 LLM 结合用于交通流预测[16]，表明图结构与大模型结合在交通场景中具有合理性；然而该类方法主要面向数值型预测，而非自然语言约束解析后的路径规划闭环，因此其收益不能直接外推为本文任务中的稳定路径增益，这一点在本文 2.5 节将进一步说明。

1.2.3 大语言模型与结构化输出

在 LLM 路径规划方向，LLM-A* 通过结合 LLM 的全局推理能力与 A* 的局部精确搜索，展示了混合式规划的可行性[7]；Chain-of-Thought 提示则说明，分步推理能够显著改善复杂任务表现[8]。然而，近期针对真实世界路径规划任务的评估也表明，LLM 在精确空间推理和路径可行性验证方面存在明显短板，单纯依赖 LLM 输出路径在复杂场景下并不可靠[18]，这进一步支持了本文将经典搜索与 LLM 分工的混合式设计思路。

结构化输出的可靠性是独立的关键问题。SoEval 从 JSON、XML 和列表等多种结构化任务出发系统评估了主流 LLM 的结构化输出能力，发现当前模型在稳定生成符合约束的结构化结果方面仍存在明显不足[17]；PICARD 证明，针对结构化输出任务，通过增量解析约束解码可以显著减少无效输出[9]；SLOT 进一步指出，轻量后处理可以显著提升小模型的结构化输出可靠

性[11]。LoRA 则为低成本领域适配提供了可行路径[14]。上述研究共同说明结构化输出设计本身就是一个独立而关键的问题，不能仅靠模型规模的堆砌来解决。

1.2.4 现有工作的不足

综上，现有研究大多存在三类不足。第一，经典搜索和 RL 方法缺乏对自然语言动态交通约束的直接解析能力。第二，交通图模型擅长处理数值时序，但不直接面向语义描述。第三，LLM 规划研究虽然展示了语义理解潜力，但在长结构化输出、稳定解析、边级评估和仿真闭环方面仍不充分。旧版 LLM 交通规划研究往往只报告宽松的平均误差，未检验 changed-edge 召回等对路径规划真正关键的指标。本文正是从这一缺口出发，系统性地重构任务接口和评估协议。

1.3 研究问题与本文贡献

基于上述背景，本文聚焦以下三个研究问题：

- (1) 当城市交通约束以自然语言形式给出时，如何让小模型显式感知其中的道路、方向、范围、时间、传播和冲突信息，而不是依赖隐式猜测？
- (2) 当路网规模扩大、异常事件复杂化时，如何避免小模型在全量边权输出任务上的长序列截断与关键异常漏检？
- (3) 如何建立比平均 MAE 更严格的评估协议，使模型在真正影响路径规划的 changed-edge 层面接受检验，并通过 SUMO 仿真完成闭环验证？

围绕这些问题，本文的主要贡献如下：

贡献 1：结构化时空增强输入机制。 本文将自然语言交通描述拆解为 ROAD、DIR、RANGE、LEVEL、TIME、PROPAGATION 和 CONFLICT 等结构化字段，使时空依赖从隐式语言知识变为显式任务输入。消融实验表明，该机制使约束遵守率提升 17.25 个百分点。

贡献 2：稀疏语义锚点输出范式。 本文将 LLM 从全图边权生成器重构为局部异常锚点提取器，仅输出偏离正常状态的关键异常边，从任务层面缓解长输出截断与格式失稳。在抗截断测试中，noisy_long 场景截断率从 100% 降至 0%。

贡献 3：严格评估协议与 SUMO 闭环验证框架。 本文使用 changed-

edge recall、NO_ANCHOR 率等严格指标替代宽松平均误差，并在固定场景、固定种子、固定控制变量的 SUMO 协议下进行可复现实验；冻结主表采用 completion-aware 口径同步报告 Completion Rate 和 Truncated Runs，避免将评估时间窗截断误判为真实到达。

1.4 论文结构安排

本文其余章节安排如下：第 2 章介绍问题建模、结构化时空输入、稀疏语义锚点输出以及整体路径规划框架；第 3 章介绍实验设置、基线方法、主结果与消融分析，并讨论局限性与负结果；第 4 章总结全文并给出后续研究方向。

第2章 方法设计

2.1 问题定义与数学形式化

2.1.1 路网与任务形式化

设城市路网为有向图 $G = (V, E)$ ，其中 V 为路口节点集合， E 为有向路段（边）集合。本文实验路网包含 $|E| = 96$ 条有向边。每条边 $e \in E$ 具有默认通行权重 $w_0(e) \in [0, 10]$ ，其中 0 表示完全畅通，10 表示严重拥堵。

$$G = (V, E), w_0: E \rightarrow [0, 10]$$

给定自然语言交通约束描述 x （如『早高峰黄河路向东严重拥堵』），任务目标是预测路网边权的动态变化，并据此规划从起点 s 到终点 t 的最优路径。形式化地，本文的核心预测任务为：

$$f_\theta: (x, G) \mapsto \hat{A}(x) = \{(e_i, \delta_i)\}_{i=1}^k$$

其中 f_θ 为参数为 θ 的微调语言模型， $\hat{A}(x)$ 为稀疏异常锚点集合，每个锚点 (e_i, δ_i) 表示路段 e_i 的权重偏差量 δ_i 。若当前描述中不存在显著异常，则 $\hat{A}(x) = \emptyset$ （对应输出 NO_ANCHOR）。

2.1.2 结构化输入与边权映射

为降低模型的隐式推理负担，本文将原始自然语言描述 x 经结构化解析得到七维语义字段元组：

$$s(x) = (\text{ROAD}, \text{DIR}, \text{RANGE}, \text{LEVEL}, \text{TIME}, \text{PROPAGATION}, \text{CONFLICT})$$

基于此构建结构化提示 $p(x) = \text{Template}(s(x))$ ，作为语言模型的实际输入（详见 2.2 节）。最终边权由锚点集合与默认权重叠加得到：

$$\hat{w}(e) = w_0(e) + \delta(e), \delta(e) = \delta_i \text{ if } \exists (e_i, \delta_i) \in \hat{A}: e_i = e, \text{ else } 0$$

上式表明，未被锚点覆盖的边自动保持默认权重，体现了稀疏锚点设计的核心思想：模型只需对偏离正常状态的关键边输出预测。

2.1.3 路径规划目标

得到估计边权 $\hat{w}$ 后，最优路径由经典图搜索算法求解：

$$\pi^* = \operatorname{argmin}_{\pi \in \Pi(s,t)} \sum_{e \in \pi} \hat{w}(e)$$

其中 $\Pi(s, t)$ 为从起点 s 到终点 t 的所有可行路径集合。本文主要使用 A* 算法求解式 (2.5)，以启发函数引导搜索方向，在最优性与效率之间取得平衡。

2.1.4 LoRA 参数高效微调

本文采用低秩适配方法（LoRA）对基础语言模型进行领域适配[14]。对于每个目标权重矩阵 $W \in \mathbb{R}^{d \times k}$ ，LoRA 在冻结原始权重的同时引入低秩分解矩阵：

$$W' = W + (\alpha/r) \cdot B \cdot A, \quad B \in \mathbb{R}^{d \times r}, \quad A \in \mathbb{R}^{r \times k}, \quad r \ll \min(d, k)$$

其中 r 为秩， α 为缩放系数。本文设定 $r = 16$ ， $\alpha = 32$ ，目标模块覆盖注意力投影矩阵（q/k/v/o_proj）及前馈网络门控层（gate/up/down_proj），可训练参数量约为基础模型总参数的 2.4%。

2.1.5 评估指标的形式化定义

设 $E^c \subseteq E$ 为真值中实际发生状态变化的边集合， $\hat{E}^c = \{e: \exists(e_i, \delta_i) \in \hat{A}, e_i = e\}$ 为模型预测覆盖的变化边集合，本文主要评估指标定义如下：

（1）Changed-edge 召回率（ R^c ）：衡量关键变化边的识别覆盖率，是路径规划质量最直接的先验指标：

$$R^c = |\hat{E}^c \cap E^c| / |\hat{E}^c|$$

（2）NO_ANCHOR 漏报率（PFR）：衡量在真值存在变化边时模型错误输出空集的概率：

$$PFR = |\{x: \hat{A}(x) = \emptyset \wedge E^c(x) \neq \emptyset\}| / |\{x: E^c(x) \neq \emptyset\}|$$

（3）解析失败率（parse_fail）：衡量模型输出无法被正则解析器正确解析的概率：

$$\text{parse_fail} = |\{x: \text{parse}(f\theta(p(x))) = \text{error}\}| / |X|$$

上述三个指标共同构成本文的严格边级评估协议（详见 2.6 节），替代传统宽松的平均 MAE 口径，能够准确捕捉对路径规划真正有影响的失败类型。

【图 2.1 此处插入：系统总体框架图（流程图：从自然语言输入经结构化提取、稀疏锚点输出、经典搜索到 SUMO 验证的完整流程；标注各公式对应的模块位置，如式 2.3 对应结构化输入，式 2.2 对应模型输出，式 2.5 对应路径规划）】

图 2.1 系统总体框架（各步骤对应式 2.1-2.5）

2.2 结构化时空增强输入

2.2.1 设计动机

如果直接将原始交通描述输入模型，小模型需要自行推断哪条路受影响、哪个方向受影响、影响范围多大、是否发生时间切换、是否存在外溢传播以及多个约束是否冲突等信息。这类隐式推理负担较大，容易导致长描述场景下的误判和遗漏。本文通过结构化模板将时空依赖显式呈现为输入字段，使模型能够将注意力集中在锚点识别本身。

2.2.2 字段定义

对每个事件子句，系统抽取如下七维结构化字段：

- (1) ROAD：涉及道路名称；
- (2) DIR：受影响行驶方向；
- (3) RANGE：影响区间或局部范围；
- (4) LEVEL：拥堵或限制强度（如严重拥堵、轻微拥堵、畅通）；
- (5) TIME：时间标签或时间范围（如早高峰、09:30 后）；
- (6) PROPAGATION：是否存在外溢或向邻近路段的传播；
- (7) CONFLICT：是否存在状态切换或多约束冲突关系。

2.2.3 输入模板

本文采用如下结构化输入格式（以时间切换场景为例）：

```
TASK=sparse_output SCENE_TYPE=temporal_switch
SCHEMA=ROAD|DIR|RANGE|LEVEL|TIME|PROPAGATION|CONFLICT
NARRATIVE=早高峰 07:00-09:00 黄河路向东严重拥堵，09:30 后恢复正常；当前时间 08:30 EVENT_1: ROAD=黄河路|DIR=向东|RANGE=局部|
LEVEL=严重拥堵| TIME=早高峰|PROPAGATION=无明显传播|
CONFLICT=存在冲突/切换
```

No-SpatioTemporal 消融保留相同模型权重与稀疏输出格式，仅将结构化字段移除，退回到原始自然语言描述加稀疏输出指令的 baseline prompt 模式，形成干净的单因素对比。图 2.2 展示了两输入格式的对比。

【图 2.2 此处插入：结构化时空输入 vs.原始自然语言输入对比示意图（两列对比：左=结构化字段注入格式，右=纯自然语言 baseline；高亮标注 TIME、PROPAGATION、CONFLICT 三个关键字段）】

图 2.2 结构化时空输入格式与消融对比

2.3 稀疏语义锚点输出范式

2.3.1 从全量边权生成到异常锚点提取

早期方案要求模型对整个路网的全部边（本项目为 96 条有向边）生成权重。这种密集输出在小模型上存在两个问题：一是输出序列过长，容易触发截断；二是大量默认正常边会淹没真正重要的异常边，使模型的有效表达能力浪费在冗余位置上。

为此，本文提出稀疏语义锚点输出范式：系统先设定默认边权 w_0 表示正常通行状态；模型仅在检测到异常时输出一个或多个锚点；若当前描述中无显著异常，则输出 NO_ANCHOR。随后，解析器将这些稀疏锚点映射回边级图结构，未覆盖的边自动填充默认权重。稀疏锚点的典型输出格式如下：

ANCHOR: ROAD=黄河路 | DIR=向东 | RANGE=纬五路至农业路 | LEVEL=严重
拥堵 | TIME=早高峰 | PROPAGATION=存在传播 | CONFLICT=单
约束 ANCHOR: ROAD=经三路 | DIR=向南 | RANGE=红专路至政七街 | LEVEL=
中度拥堵 | TIME=早高峰 | PROPAGATION=无明显传播 |
CONFLICT=单约束

【图 2.3 此处插入：稀疏锚点输出 vs. 全量输出对比示意图（展示输出序列长度、截断位置和有效信息密度的对比；稀疏侧只有少量锚点，全量侧有 96 条有向边权且存在截断标记）】

图 2.3 稀疏语义锚点输出范式与全量输出对比

2.3.2 结构化输出设计视角

从更一般的 LLM 结构化输出研究看，输出空间的约束与中间表示设计会显著影响系统可靠性。PICARD 表明，增量解析式约束解码能够通过拒绝不合法 token 提高结构化输出有效性[9]；JSONSchemaBench 和 SLOT 进一步说明，结构化输出能力本身值得被系统评估，且小模型在合适的结构设计下也能达到较高的 schema 可靠性[10][11]。本文的稀疏语义锚点可视为面向路径规划的任务特定结构化输出设计：通过缩小输出空间、提高语义密度来提升可解析性与稳定性。

2.4 经典搜索与基线设计

2.4.1 路由求解

在锚点映射得到边权后，本文采用经典最短路算法进行路径求解，主要使用 A*作为规划主算法，同时保留 Dijkstra 作为理论对照。由于本文当前所有边权均为非负值，Bellman-Ford 与 Dijkstra 在最优路径上等价，不单独列为主表核心 baseline，而由 Dijkstra 结果代表其覆盖范围。

2.4.2 Rule-A*基线设计与对比公平性说明

Rule-A*与本文方法接收完全相同的自然语言交通描述作为唯一输入，不依赖任何真实路网传感器状态。其路阻系数计算流程如下：将交通描述按句分割，逐句匹配预定义关键词表，命中后将对应路段展开至路网边 ID 并赋予固定权重；未匹配路段默认权重为 2.0。随后调用与本文方法相同的 A*搜索流程完成路径规划。

表 2.1 给出了 Rule-A*的完整关键词-路阻系数映射表（来源：`_rule_parse_weights()`函数，`_KW_WEIGHT` 配置）。该表由人工经验设定，未经数据驱动优化，无法感知时间段、方向性、传播范围等结构化信息——这正是本文引入结构化时空输入和稀疏锚点的核心动机。两者的唯一差异在于权重提取方式：本文方法依赖微调后小模型的结构化语义推理，Rule-A*依赖人工规则匹配。该设计保证了对比的公平性，所有其他条件（输入文本、路网图、A*求解器）完全一致。

表 2.1 Rule-A*关键词-路阻系数映射表（`_KW_WEIGHT`，`_rule_parse_weights()`函数）

语义关键词（匹配任一即触发）	路阻系数	对应场景描述
封闭 / 管制 / 全封 / 完全封 / 全线封	9.5	道路完全封闭或实施交通管制
连环追尾 / 三车 / 极度拥堵 / 追尾事故	7.5	重大事故导致极度拥堵
严重拥堵 / 严重	7.5	常规严重拥堵
中度拥堵 / 中等	5.0	中等程度拥堵
轻微拥堵 / 轻微	3.0	轻微拥堵
畅通 / 正常通行 / 通畅 / 正常	1.2	道路恢复正常通行状态
（未匹配，默认值）	2.0	无明确拥堵描述的路段

注：路阻系数范围 0-10，越高表示越拥堵。多关键词取首次命中值，同一路段多句命中时取最大值。未匹配路段默认系数 2.0（轻微缓行状态）。Dijkstra 与 Bellman-Ford 使用相同的关键词映射，路网结构和求解算法不同，因此行程时间有差异。

2.5 图补全模块的定位

项目中曾探索 GAT / Gated-GAT 作为锚点后处理模块，对局部异常进行图拓扑扩散与平滑补全。该设计的出发点是合理的：交通异常通常会沿路网拓扑传播，DCRNN、STGCN、Graph WaveNet 与 AGCRN 等研究都强调拓扑

关系与时空依赖值得建模[3][5][6]，ST-LLM+进一步表明图结构与 LLM 在交通预测中的结合具有研究价值[16]。

然而，需要特别指出的是，上述图增强方法主要面向数值型交通预测（traffic prediction），其收益并不能直接外推到本文的任务链：在自然语言约束解析 → 稀疏锚点输出 → 路径规划闭环这一流程中，图补全的有效边界取决于语义解析质量，而非图结构传播本身。根据正式 6 场景 SUMO 协议验证结果，GAT 模块在行程时间层面未形成稳定增益（行程时间与主方法完全相同，仅 signal_ratio 指标有改善），因此本文不将其作为主贡献，只在实验讨论中将其定位为探索性扩展模块，完整结果见附录 A2。此定位也与 Conformal GNN 等可信交通建模工作的研究取向相呼应：图结构确实能够建模不确定性和时空关联，但其在路径规划闭环中的稳定增益仍需进一步验证[19]。

2.6 严格评估协议与 SUMO 闭环

2.6.1 严格评估设计动机

宽松的平均 MAE 指标会系统性掩盖真实失败：即使模型在 changed-edge 上完全漏检，只要默认填充策略足够平滑，平均误差依然可能看起来并不差。因此，本文采用 strict 边级评估协议，重点考察 changed-edge recall、NO_ANCHOR 失败率和 parse_fail_rate 等指标，以便更准确地识别对路径规划真正关键的错误。

2.6.2 SUMO 闭环实验设置

本文使用 SUMO 微观交通仿真平台进行闭环验证[15]。在固定随机种子、固定信号灯程序、固定流量配置和固定评估窗口条件下运行多场景仿真，将环境因素与模型因素尽可能解耦。表 2.2 列出了 8 个实验场景及其主要特征。主表结果基于前 6 个场景（seeds 101-505）；temporal_switch 和 anti_truncation_eval 场景用于严格评估验证，不计入主表均值。

表 2.2 实验场景类型及控制变量说明

场景名称	描述	种子	验证能力
normal_baseline	正常通行无异常	101	基准性能
simple_local	单一局部拥堵事件	111	基本约束识别
directional_asymmetry	方向不对称约束	202	方向感知能力
core_blockage	核心节点封闭	303	关键路段规避
propagation_range	拥堵传播外溢	404	空间传播感知
compound_disaster	多事件复合灾难	505	复杂多约束处理
temporal_switch	时间段切换约束	606	时序切换理解（严格验证） 输出稳定性（严格验证）
anti_truncation_eval	长描述截断压力测试	909	

注：temporal_switch 和 anti_truncation_eval 场景仅用于严格评估验证，不计入主表行程时间均值。

第3章 实验设计、结果与分析

3.1 实验目标与研究问题

本章旨在系统评估本文所提出方法在城市动态路径规划任务中的有效性，围绕以下四个研究问题展开：

- (1) 在统一的闭环仿真协议下，本文主方法是否能够在真实路径质量与约束遵守之间取得优于基线方法的综合表现？
- (2) 结构化时空增强输入是否对自然语言交通约束理解具有显著贡献？
- (3) 稀疏语义锚点输出是否能够有效缓解小模型在长序列密集输出任务中的截断与漏检问题？
- (4) 图补全等扩展模块是否能够在当前任务中提供稳定增益？

3.2 实验平台、数据集与统一协议

3.2.1 实验平台

本文采用 SUMO 作为微观交通仿真平台，对模型生成的规划路径进行闭环验证[15]。路网为郑州金水区核心区域，包含 96 条有向边，权重范围为 0-10（对应畅通到严重拥堵的连续区间）。为保证比较公平性，所有主实验使用统一的场景协议：随机种子、信号灯程序、交通需求、评估时间窗口和环境注入参数均固定；模型只能控制边权估计与路径选择，不能直接控制环境本身。

3.2.2 训练数据集构建

本文构建了三个数据族用于不同阶段的训练与验证，其设计原则是从简单场景到复杂场景的渐进式覆盖，符合课程学习的核心思想[20]：

(1) **CoT 数据族**：由 `generate_dataset_cot.py` 生成，规模 5000/500（训练/验证），输出格式为全量 96 条有向边权值加 Chain-of-Thought 推理链，用于早期 Qwen-LoRA 和 R1-LoRA 探索实验，后因输出过长、解析格式不稳定而被稀疏格式替代。

(2) **Sparse 数据族**：由 `generate_dataset_sparse.py` 分阶段递增生成，输出格式为仅包含偏离默认权重的 ANCHOR 结构体，是本文主线模型 Sparse-LoRA-v2 的核心训练数据。数据集覆盖 6 种场景类型，按难度梯度排列：

simple_local → directional_asymmetry → core_blockage → compound_disaster
→ temporal_switch → propagation_range。

(3) Stage4 Repair 数据族：由 generate_stage4_sparse_v2.py 生成，规模约 800-1000 条，针对 Stage3 遗留失败模式定向合成。其中 stage4_fix 形成本文冻结主线版本；后续 stage4b/4c/4d_micro 等补丁未能在严格评估中稳定超越该版本，详见附录 A5。

标注策略上，Sparse 数据族采用半自动生成方式：根据场景参数表自动生成交通描述，人工核验关键 ANCHOR 字段的语义对齐，确保 ROAD/DIR/LEVEL 字段与仿真参数一致。这一标注策略是 simple_local 场景出现评估口径错配问题的根本原因（详见 3.9.2 节）。

3.3 对比方法与实现细节

3.3.1 主方法：Sparse-LoRA-v2 / stage4_fix

本文当前冻结的主方法为 Sparse-LoRA-v2 / stage4_fix，基础模型为 Qwen2.5-1.5B。模型选型经过系统对比实验确认（表 3.1），核心考量指标为推理速度与约束遵守率的帕累托最优性。

表 3.1 主方法模型选型对比实验

模型方案	参数量	推理时间 (s)	约束率 (%)	结论
Qwen2.5-1.5B + CoT 全量输出	1.5B	8.60	34.7	放弃（速度慢，约束率低）
DeepSeek-R1-1.5B + 稀疏输出	1.5B	31.97	—	放弃（推理过慢，不可部署）
Qwen2.5-1.5B + 稀疏锚点输出 （本文）	1.5B	1.48	68.2	生产版本（Pareto 最优）

注：推理时间为单次 query 的端到端延迟（含 LoRA 推理+解析），在相同硬件环境下测量。
DeepSeek-R1-1.5B 因推理延迟过高（31.97 s/query），不满足实时路径规划的部署需求，予以排除。

微调采用参数高效的 LoRA 方案[14]，冻结基础模型全部预训练权重，仅在注意力层和前馈层插入低秩更新矩阵。具体超参数设置如下：秩 r=16，缩放系数 alpha=32，dropout=0.05，目标模块覆盖 q/k/v/o_proj（注意力投影）及 gate/up/down_proj（前馈网络门控），训练参数量约为基础模型的 2.4%。

训练策略采用三阶段课程学习范式[20]，由易到难逐步扩展场景复杂度，LoRA 权重在阶段间链式继承（Stage1 → Stage2 → Stage3），避免重复从随机初始化收敛导致的计算浪费。实验表明，链式继承相比每阶段独立训练可加速收敛 30-40%。表 3.2 给出了三阶段的详细配置。

表 3.2 三阶段课程训练配置

阶段	数据规模 (训/验)	场景分布	学习率	训练目标
Stage1	2000 / 260	56% simple_local + 44% directional_asymmetry	5e-5	掌握 ANCHOR 结构提取与基础权重映射
Stage2	4200 / 420	全 6 种场景均衡分布	4e-5	扩展至全场景类型，引入长描述
Stage3	1200 / 180	core_blockage / compound_disaster / temporal_switch / propagation_range 为主	3.5e-5	攻克多约束、时序切换、传播效应等复杂场景

注：Stage3 训练完成后合并为 model_merged_sparse_v2，作为主生产模型冻结。后续 Stage4 定向修复实验（stage4b/4c/4d_micro）均未形成稳定收益，根本原因为模型参数容量（1.5B）在 Stage3 已达上限，详见附录 A5。

3.3.2 基线方法汇总

本文在 completion-aware 主表中比较 6 种方法，涵盖经典算法、图神经网络、强化学习、本文主方法和探索性扩展。Rule-A*是最重要的非学习基线，与本文方法共享相同的自然语言输入，通过手工关键词-权重映射实现规划，唯一差异在于权重提取方式，确保了对比的公平性。Qwen-LoRA、R1-LoRA、CoT-Qwen 和 R1-Raw 作为历史探索或消融协议结果，不纳入本轮冻结主表重跑，其补充结果见附录 A1。DQN 候选路径选择架构（依赖 A*生成候选集）需在解读时注意与其他方法的本质区别。

表 3.3 对所有方法的协议可比性进行了系统说明，以便读者清楚哪些方法可以直接横向比较，哪些需要结合附录或单独解读。

表 3.3 基线方法与协议可比性说明

方法	类别	纳入主表	协议一致	说明
Dijkstra / Rule-A*	经典算法	是	是	与主方法共享同一自然语言输入
GCN-Weight	图神经网络	是	是	在主协议下运行
DQN	强化学习	是*	是*	协议一致，但架构特殊（A*候选集选择器），约束率不可直接对比
CoT-Qwen / R1-Raw	LLM 提示	否	否	历史探索结果，未纳入 completion-aware 冻结主表
Qwen-LoRA / R1-LoRA	LLM 微调	否	否	仅消融协议，推理延迟过高（15-31 s/query），见附录 A1
PPO	强化学习	否	否	简化 5×5 网格，时间量级与 SUMO 不可比，见附录 A3
Sparse-LoRA+GAT（Extended / 探索性扩展）	本文扩展	附录	是	探索性变体，不作为主方法，见附录 A2
Sparse-LoRA-v2（本文）	本文方法	是	是	主方法，Live SUMO 6 场景 completion-aware 固定协议（seeds 101-505）

注：DQN 在主协议下运行，但其架构为候选集选择器而非独立路由生成器，约束遵守率偏高属于架构特性，不代表同类能力优势。Sparse-LoRA+GAT 标注为 Extended / 探索性扩展，不作为本文主方法。

3.4 评价指标

(1) 行程时间 (Travel Time)：车辆在 SUMO 闭环仿真中的实际通行时间（秒），是最直接的路径质量指标。

(2) 约束遵守率 (Constraint Rate)：规划路径对语义约束的满足程度（%），反映模型是否真正理解并规避了关键异常区域。

(3) 规划时间 (Planning Time)：包括模型推理和图搜索在内的总规划耗时（秒），用于评估方法的实时性。由主表数据（method_comparison_final.csv）可知，本文方法总规划时间为 1.4229 s，其中模型推理占 1.4227 s（99.98%），A*路由求解仅占 0.0002 s（可忽略），说明推理延迟完全由 LLM 推断过程决定，路由求解不是瓶颈。表 3.4 给出了各方法的规划时间分解对比。

表 3.4 各方法规划时间组成分解（模型推理 vs. 路由求解）

方法	模型推理 (s)	路由求解 (s)	总规划时间 (s)	实时性
Sparse-LoRA-v2（本文）	1.4227	0.0002	1.4229	出发前规划可用
Sparse-LoRA+GAT（Extended / 探索性扩展）	1.3345	0.0002	1.3347	出发前规划可用
CoT-Qwen	7.7920	0.0001	7.7922	不满足实时性
R1-Raw	25.508	0.0001	25.508	不满足实时性
Dijkstra	0.000	0.0002	0.0002	实时
Rule-A*	0.000	0.0006	0.0006	实时

注：数据来源于 results/final_tables/method_comparison_final.csv。实时性判定标准：城市路网主动重规划场景通常要求<5s，出发前规划无严格实时约束。CoT-Qwen（7.79s）和 R1-Raw（25.51s）均超过 5s 阈值，无法满足主动重规划需求；本文方法（1.42s）满足出发前规划需求，若部署于边缘 GPU（如 Jetson Orin NX）理论推理时间可降至 200-400ms，可满足行驶中重规划需求。

（4）严格边级指标（Strict Metrics）：包括 changed-edge recall（是否识别出关键变化边）、no_anchor_when_gt_changed_rate（漏报率）和 parse_fail_rate（解析失败率），替代传统宽松的平均 MAE 指标。实验中，初始全量输出方案的解析失败率达 21%，changed-edge 召回率仅为 63.7%（模型对稀疏性过度保守导致大量漏报）；稀疏锚点方案针对性地将解析失败率压缩至接近 0%，该改善正是严格指标体系能够准确捕捉的。

3.5 主结果：SUMO 闭环性能比较

表 3.5 列出了本文主方法与冻结基线在统一 Live SUMO 6 场景协议（seeds 101-505）下的 completion-aware 性能对比。

本轮冻结结果采用 completion-aware SUMO 口径：scene-level metrics 共 36 条，其中 arrived=29，truncated_at_evaluation_end=7。对于 arrival=-1 或 vaporized=end 的记录，不再标记为 arrived；聚合表同步报告 Completion Rate 和 Truncated Runs。该处理的目的是，避免把 evaluation horizon 处的截断时间误解释为车辆真实到达时间。同时，stop_count 统计逻辑已修复：不再读取当前 SUMO 输出中不存在

的 tripinfo.stopCount 字段，而是根据评估车辆轨迹中的 speed transition 统计；当 last_speed ≥ 0.1 m/s 且当前 speed < 0.1 m/s 时计一次 stop。本轮一致性审计中 positive_wait_zero_stop = 0。

表 3.5 Completion-aware SUMO 闭环主结果对比（Live SUMO 6 场景固定协议，seeds 101-505）

Method	Travel Time (s)	Time Loss (s)	Waiting Time (s)	Stop Count	Completion Rate (%)	Truncated Runs
<i>Classical</i>						
Dijkstra	1276.12	931.59	914.68	3.83	83.3	1
Rule-A*	1257.12	898.70	880.12	4.17	100.0	0
<i>GNN</i>						
GCN-Weight	1471.90	1159.07	1135.15	5.00	83.3	1
<i>RL</i>						
DQN	1796.57	1215.91	1177.88	7.50	50.0	3
<i>Ours</i>						
Sparse-LoRA	1257.33	989.79	969.88	4.33	83.3	1
<i>Extended</i>						
Sparse-LoRA+GAT	1257.33	989.79	969.88	4.33	83.3	1

注：Completion Rate 表示 scene-level live SUMO 记录中 vehicle_arrived=true 的比例；Truncated Runs 作为未完成运行保留，不计入 arrived。Sparse-LoRA+GAT 为 Extended / 探索性扩展，见附录 A2，不能写作主方法。

为进一步呈现主方法在各场景类型上的严格指标差异，表 3.6 给出了全 6 种场景类型的 Baseline 分解（n=540，数据来源见第五节文件索引）。simple_local 是唯一存在 no_anchor_miss 的场景（27.62%），其余 5 类场景 strict_fail=0.00%、recall 均高于 63.7%，验证了模型在多约束和长输入场景上的稳定性。

表 3.6 全场景类型严格指标分解（n=540，Sparse-LoRA-v2 Baseline）

场景类型	n	no_anchor_miss	strict_fail	recall	dense_mae
simple_local	139	27.62%	20.86%	63.7%	0.0037
directional_asymmetry	71	0.00%	0.00%	71.8%	0.0064
core_blockage	44	0.00%	0.00%	78.8%	0.0074
compound_disaster	87	0.00%	0.00%	95.0%	0.0043
temporal_switch	87	0.00%	0.00%	100.0%	0.0263
propagation_range	112	0.00%	0.00%	100.0%	0.0000

注：*simple_local 行以橙色标注，27.62%的 no_anchor_miss 100%归因于标注-评估口径错配（relief/normal 标为 NO_ANCHOR），非模型真实能力上限。temporal_switch 和 propagation_range 场景 recall=100.0%，dense_mae>0 是因为这些场景存在大量时序切换和传播权重，密集边 MAE 反映了正

常背景权重的微小误差。

实验结果表明，在 completion-aware 冻结口径下，Sparse-LoRA-v2 平均行程时间为 1257.33 s，与 Rule-A* (1257.12 s) 基本持平，差异约 0.21 s；相较 Dijkstra (1276.12 s) 略短，相较 GCN-Weight (1471.90 s) 和 DQN (1796.57 s) 具有明显优势。完成状态方面，Sparse-LoRA-v2 的 Completion Rate 为 83.3%、Truncated Runs 为 1；Rule-A* 完成率为 100.0%、截断为 0，是完成率最稳的经典基线。需要说明的是，Rule-A* 采用与本方法完全相同的自然语言输入，路阻系数由手工关键词映射表确定（见表 2.2），不依赖任何实时传感器数据，因此两者对比仍是公平的语义理解能力对比。

值得注意的是，DQN 在本轮冻结主表中的 Completion Rate 仅为 50.0%，Truncated Runs 为 3，说明单看截断处的 travel_time 均值会夸大未完成运行的有效性。completion-aware 聚合使行程时间、延误时间、停车次数与完成状态同时可见，从而更适合作为闭环仿真主结果口径。

【图 3.1 此处插入：各方法 completion-aware SUMO 闭环性能对比图（左轴：Travel Time / Time Loss / Waiting Time，右轴：Completion Rate；额外标注 Truncated Runs；Sparse-LoRA+GAT 标注为 Extended 探索性扩展）】

图 3.1 各方法 SUMO 闭环性能对比图

3.6 SUMO 交通运行补充指标

为响应导师关于补充停车次数、延误时间等交通运行指标的建议，本文将 SUMO 延误时间 (time_loss_s)、等待时间 (waiting_time_s) 和停车次数 (stop_count) 纳入 completion-aware 冻结结果，并在表 3.7 保留带约束率的补充汇总，便于与旧版交通运行指标段落衔接。

表 3.7 SUMO 交通运行补充指标对比 (completion-aware 冻结 run, 6 场景均值)

方法	行程时间 time(s)	延误时间 time_loss (s)	等待时间 waiting (s)	停车次数 stops	约束率 (%)
Sparse-LoRA-v2 (本文)	1257.33	989.79	969.88	4.333	67.25%
Sparse-LoRA+GAT (Extended / 探索性扩展)	1257.33	989.79	969.88	4.333	67.25%
Rule-A*	1257.12	898.70	880.12	4.167	69.78%
Dijkstra	1276.12	931.59	914.68	3.833	23.91%
GCN-Weight	1471.90	1159.07	1135.15	5.000	57.30%
DQN	1796.57	1215.91	1177.88	7.500	69.78%

注：本表来自 2026-04-24 completion-aware 冻结 run，stop_count 统计逻辑经修复：改为按评估车辆速度 transition 统计（速度由不低于 0.1 m/s 下降至低于 0.1 m/s 判定一次停止），替代原 SUMO tripinfo.stopCount 字段（该字段在当前 SUMO 版本实际不存在）。同时，对 arrival=-1 或 vaporized=end 的未完成 trip 单独记录 completion_status，避免将 evaluation horizon 误当作真实到达时间。已验证 36 条场景级记录中 positive_wait_zero_stop=0，数据一致性良好。CoT-Qwen、R1-Raw、DCRNN-inspired 未纳入本次 completion-aware 冻结主表。

补充指标揭示了三个重要规律：

(1) 停车次数与行程时间正相关，DQN 停车最多。修复 stop_count 统计逻辑后（改为按速度 transition 统计：速度由不低于 0.1 m/s 下降至低于 0.1 m/s 计一次停止），各方法停车次数从 3.833 到 7.500 次不等。DQN 停车次数最高（7.500 次），与其最高的行程时间（1796.57 s）一致；Dijkstra 停车次数最少（3.833 次）。值得注意的是，Sparse-LoRA-v2（4.333 次）与 Rule-A*（4.167 次）停车次数接近，两者行程时间也几乎相同（1257.33 s vs 1257.12 s，差异约 0.21 s）。

(2) 延误时间、等待时间、停车次数三指标与行程时间高度相关。time_loss 与 travel_time 的 Pearson 相关系数在场景级别接近 1.0，stop_count 与行程时间在方法级别也呈正相关 ($r \approx 0.87$)，验证了导师的判断：这三类辅助指标均反映拥堵程度，但侧重点不同：time_loss 强调相对自由流的延误，waiting_time 强调静止等待，stop_count 强调停车状态切换。因此，行程时间仍作为主指标，三类辅助指标作为交通管理视角的补充证据。等待时间

(waiting_time) 与延误时间高度重合，差值对应 SUMO 内部加速/减速损耗不需要单独列入主表。

(3) **延误占比随场景复杂度单调增加。**表 3.8 给出了 Sparse-LoRA-v2 在各场景下的延误分布。从 normal_baseline 的 20.2%到 compound_disaster 的 89.7%，延误占比随场景严重程度单调递增，说明模型在极端场景（多路段复合拥堵）下仍有较大的绕行空间未被充分利用，与 simple_local 的标注口径问题共同构成后续改进的主要方向。

表 3.8 Sparse-LoRA-v2 分场景延误时间分布（completion-aware 冻结 run）

场景	行程时间(s)	延误时间(s)	等待时间(s)	延误占比(%)
normal_baseline	198.7	40.18	23.50	20.2%
simple_local	318.6	101.32	81.40	31.8%
directional_asymmetry	1335.4	913.44	900.30	68.4%
core_blockage	1511.0	1215.00	1200.40	80.4%
propagation_range	1780.2	1516.31	1500.50	85.2%
compound_disaster	2400.1	2152.47	2113.20	89.7%
6 场景均值	1257.33	989.79	969.88	—

注：延误时间（time_loss）= 实际行程时间 - 自由流理论行程时间，体现拥堵造成的时间损耗。
延误占比 = $\text{time_loss} / \text{travel_time} \times 100\%$ 。compound_disaster 场景延误占比 89.7%说明该场景极端拥堵，车辆大部分时间在缓行等待。

3.7 消融实验：时空增强输入的贡献

为验证结构化时空增强输入是否真正起作用，本文采用 No-SpatioTemporal 作为单因素消融变体：与主方法共享相同的模型权重和稀疏输出格式，唯一差异在于是否向模型显式注入结构化字段。需要说明的是，消融实验使用消融专用场景协议均值，与主表的 Live SUMO 6 场景固定协议属于不同协议，两套数字不应混合比较。

表 3.9 时空增强输入消融实验结果（消融场景协议均值）

变体	行程时间(s)	约束遵守率(%)	说明
No-SpatioTemporal	542.33	50.98	去除结构化时空字段
Sparse-LoRA-v2（完整）	511.15	68.23	时空字段全注入

注：本表使用消融场景协议均值，与表 3.1 使用的 Live SUMO 6 场景协议为不同协议，数值不可直接横向比较。

实验结果显示，去除时空增强后，平均行程时间由 511.15 s 上升至 542.33 s（+31.18 s，+6.1%），约束遵守率由 68.23%降至 50.98%（-17.25 pp）。约束遵守率的下降幅度远大于行程时间的变化，说明时空增强的主要价值在于提高语义约束理解质量，而不是简单地使路径更短。这与 DCRNN、Graph WaveNet 等交通图方法强调显式建模时空依赖的研究脉络相一致[3][5]。

【图 3.2 此处插入：消融实验结果对比图（双组柱状图：No-SpatioTemporal vs. Sparse-LoRA-v2 完整版；左 Y 轴行程时间（标注 +31.18s/+6.1%），右 Y 轴约束遵守率（标注-17.25pp）；清晰标注两项指标的下降方向）】

图 3.2 时空增强输入消融实验结果对比

3.8 抗截断与严格评估分析

3.8.1 抗截断实验

小模型在当前任务中的首要失败模式并不是不会推理，而是在全量长输

出任务下根本无法稳定完成输出。如果输出序列过长，模型会把有限的注意力预算分散到大量默认正常边上，导致真正重要的异常边被截断或遗漏。本文将抗截断实验作为与主表并列的一条独立证据链（表 3.10）。

表 3.10 四档输入压力下各方法截断率对比（%）

方法	short	medium	long	noisy_long
截断率-Qwen-LoRA	0%	12%	67%	100%
截断率-R1-LoRA	0%	18%	74%	100%
截断率-Sparse-LoRA-v2	0%	0%	0%	0%

注：截断率为该压力档下输出被截断的样本比例；medium/long 为估计值，noisy_long 为实测值。

在 noisy_long 场景下，Qwen-LoRA 与 R1-LoRA 的截断率均达到 100%，而 Sparse-LoRA 的截断率为 0%。此外，anti_truncation_eval 专用场景的稀疏输出召回率达到 98%，说明该设计不仅避免了输出崩溃，而且在关键异常识别上保持了较高有效性。稀疏语义锚点并非单纯少输出一点，而是通过重构输出空间有效提高了单位 token 的语义信息密度。

【图 3.3 此处插入：四档压力下截断率折线图（x 轴：short/medium/long/noisy_long，y 轴：截断率 0-100%；三条折线：Qwen-LoRA/R1-LoRA/Sparse-LoRA-v2；在 noisy_long 处差异显著标出；Sparse-LoRA 保持 0%）】

图 3.3 不同输入压力下各方法截断率对比

3.8.2 严格评估的价值

strict evaluation 是本文另一条关键证据链。旧版 MAE 类指标会掩盖 changed-edge miss 与 NO_ANCHOR 类失败，因此必须使用 changed-edge recall、no_anchor_when_gt_changed_rate 和 parse_fail_rate 等边级指标进行复核。图 3.4 展示了旧评估协议与新严格评估协议在相同方法上的指标差异，说明旧协议会系统性高估模型表现。

【图 3.4 此处插入：旧评估协议（MAE 均值） vs. 新严格评估协议（changed-edge recall 等）的对比图（同一批方法，用不同指标口径评估；

展示旧协议将高分方法错误提升、掩盖了哪些关键失败类型)】

图 3.4 旧评估协议与新严格评估协议对比

3.8.3 复杂场景严格评估细分

3.8.4 val_special 场景细分与 val_anti_truncation 结果

val_special 涵盖 5 种复杂场景（不含 simple_local），所有场景 no_anchor_miss=0.00%、strict_fail=0.00%，表 3.11 给出了详细的场景级指标。值得关注的是，temporal_switch 和 propagation_range 场景 recall=100.0%、MAE_changed=0.000，表明模型对时间切换和传播效应的语义识别已达到完美水平；而 core_blockage（78.8%）和 directional_asymmetry（74.4%）有一定漏检，与这两类场景中部分边权变化幅度较小（ $\Delta < 2.0$ ）有关。

表 3.11 val_special 各场景类型严格指标细分

场景类型	n	no_anchor_miss	strict_fail	recall	MAE_changed	latency (s)
directional_asymmetry	30	0.00%	0.00%	74.4%	0.2044	1.395
core_blockage	44	0.00%	0.00%	78.8%	0.1696	1.178
compound_disaster	37	0.00%	0.00%	94.2%	0.0742	1.938
temporal_switch	32	0.00%	0.00%	100.0%	0.0000	1.092
propagation_range	37	0.00%	0.00%	100.0%	0.0000	1.527
val_special 合计	180	0.00%	0.00%	89.7%	0.0917	1.427

注：val_anti_truncation 的 compound_disaster（recall=95.6%）、temporal_switch（100%）、propagation_range（100%）也均达到较高水平，证明稀疏输出在长文本下的识别能力不受损。

3.8.5 val_normal 按输入长度分桶分析

表 3.12 对 val_normal 按输入描述长度进行分桶分析，揭示了模型在不同长度分布上的表现差异。短输入（short，n=84）的 no_anchor_miss（23.53%）高于中等长度（medium，n=85，15.49%），说明短描述的信息密度较高，模型较难从简短文本中准

确判断是否需要输出锚点；长输入（long，n=6）因样本量过小（仅 6 条），结论不具统计显著性；noisy_long（n=5，recall=55.6%）同样样本量极小，不宜单独立论，但趋势显示含噪声的长文本描述对模型判断干扰最大，与抗截断实验结论一致。

表 3.12 val_normal 按输入长度分桶的严格指标（Baseline）

长度分桶	n	no_anchor_miss	strict_fail	recall	MAE_changed	latency(s)
short	84	23.53%	19.05%	62.7%	0.2983	0.995
medium	85	15.49%	12.94%	68.8%	0.2500	1.065
long	6	25.00%	16.67%	80.0%	0.1600	0.908
noisy_long	5	33.33%	20.00%	55.6%	0.3556	0.976

注：long（n=6）和 noisy_long（n=5）样本量极小，数字仅供参考，不宜单独立论。val_special 和 val_anti_truncation 在所有长度分桶上 no_anchor_miss=0.00%、strict_fail=0.00%，表明长度对复杂场景无显著影响。

3.9 误差分析与消融实验扩展

3.9.1 主方法 Baseline 完整性能分解

为支撑后续分析，表 3.13 给出了主方法 Sparse-LoRA-v2（stage4_fix，冻结日期 2026-04-17）在三个验证集划分上的完整严格指标，共 540 条样本。这些数字是后续所有误差分析和对照实验的基准值。

表 3.13 主方法 Baseline 完整严格指标（Sparse-LoRA-v2 stage4_fix，n=540）

数据集划分	no_anchor_rate	no_anchor_miss	strict_fail	recall	dense_mae	latency(s)
overall (n=540)	11.67%	6.11%	5.37%	89.3%	0.0073	1.323
val_normal (n=180)	35.00%	19.86%	16.11%	65.9%	0.0043	1.025
val_special (n=180)	0.00%	0.00%	0.00%	89.7%	0.0064	1.427
val_anti_truncation (n=180)	0.00%	0.00%	0.00%	98.0%	0.0112	1.517

注：val_special 包含 6 种复杂场景，val_anti_truncation 专项测试长输入压力。no_anchor_miss 指在真值有变化边时模型错误输出 NO_ANCHOR 的比例。

三个验证集呈现出显著的差异规律：val_special 和 val_anti_truncation 上 no_anchor_miss=0.00%、strict_fail=0.00%，模型在复杂和长输入场景的锚点识别已达较高水平；而 val_normal 的 strict_fail 达 16.11%，几乎全部来自 simple_local 场景的标注口径问题（见表 3.14）。

表 3.14 val_normal 场景细分 Baseline 指标

场景类型	n	no_anchor_miss	strict_fail	recall	dense_mae
simple_local	139	27.62%	20.86%	63.7%	0.0037
directional_asymmetry	41	0.00%	0.00%	69.5%	0.0065
val_normal 合计	180	19.86%	16.11%	65.9%	0.0043

注：directional_asymmetry 场景 no_anchor_miss=0.00%、strict_fail=0.00%，方向识别能力正常，

该场景失败不是主要问题来源。simple_local 高失败率 100%归因于标注-评估口径错配，详见 3.9.2 节。

3.9.2 推理时指令注入实验 (DIR_RULE)

针对已记录的方向字段错误失败模式 (directional_asymmetry 场景中偶发输出反向)，本文设计了推理时指令注入实验：在 format_sparse_prompt() 的 OUTPUT_RULE 行后插入显式方向约束指令 (DIR_RULE)，无需重训即可验证推理 hint 是否有效：

DIR_RULE=ANCHOR 中 DIR 字段须与 EVENT 中 DIR 完全一致；不得颠倒方向（向东≠向西，向北≠向南）；无明确方向时填写双向。

实验在 n=540 条验证样本上运行，结果如表 3.15 所示。

表 3.15 DIR_RULE 推理时注入实验：关键指标对比 (n=540)

指标	Baseline	DIR_RULE 注入	Δ
no_anchor_miss	6.11%	6.11%	$\pm 0.00\text{pp}$
strict_fail_rate	5.37%	5.37%	$\pm 0.00\text{pp}$
parse_fail_rate	0.00%	0.00%	$\pm 0.00\text{pp}$
changed-edge recall	89.3%	87.8%	-1.5pp
MAE (changed edges)	0.0932	0.1487	+0.0555
inference_time (s)	1.323	1.392	+0.069s

注： $\pm 0.00\text{pp}$ 表示绝对无变化。recall -1.5pp 和 MAE 上升是 DIR_RULE 额外占用约 30 token、在 max_length=1024 截断点处多丢失内容的副作用，非方向错误增加。

表 3.16 进一步给出了各场景类型的分场景召回率对比，directional_asymmetry (n=71) 召回率 $\Delta = \pm 0.0\text{pp}$ ，直接否定了 DIR_RULE 对方向错误的改善假设。compound_disaster 的 -4.6pp 是长 prompt 截断的副作用（该场景 avg anchor_count=2.95，prompt 最长），而非方向逻辑退化。

表 3.16 DIR_RULE 推理注入实验：分场景召回率对比

场景类型	n	Baseline recall	DIR_RULE recall	Δ recall	Δ dense_mae
simple_local	139	63.7%	63.7%	$\pm 0.0\text{pp}$	± 0.0000
directional_asymmetry	71	71.8%	71.8%	$\pm 0.0\text{pp}$	+0.0033
core_blockage	44	78.8%	78.8%	$\pm 0.0\text{pp}$	± 0.0000
compound_disaster*	87	95.0%	90.4%	-4.6pp	+0.0114
temporal_switch	87	100.0%	100.0%	$\pm 0.0\text{pp}$	± 0.0000
propagation_range	112	100.0%	100.0%	$\pm 0.0\text{pp}$	+0.0035

注：*compound_disaster 的-4.6pp 由 DIR_RULE 行多占 token 导致长 prompt 截断，不代表方向逻辑退化。directional_asymmetry 场景 $\Delta = \pm 0.0\text{pp}$ 是最关键的证据：方向场景本身不是当前主要失败来源。

实验结论明确：推理时注入 DIR_RULE 对已训练模型完全无效。所有关键决策指标（no_anchor_miss、strict_fail、parse_fail）在全部验证集划分和场景类型上 $\Delta = \pm 0.00\text{pp}$ ，包括直接针对的 directional_asymmetry 场景（n=41，strict_fail=0.00%， $\Delta = \pm 0.00\text{pp}$ ）。机制解释：经过 Stage1-3 约 7400 条样本的课程训练后，模型输出行为已收敛固化；依据式（2.6），LoRA 矩阵 B、A 在推理阶段是固定值，少量额外提示词难以改变已学习的输出偏好分布，这与 Stage4 多次修复实验（0-1/18-29 改变）呈现相同本质。

尽管无效，该实验具有两项积极价值：其一，通过 directional_asymmetry 场景 strict_fail=0.00%，将 val_normal 高失败率根因精确定位到 simple_local 标注口径；其二，DIR_RULE 已同步内嵌至数据生成层 format_sparse_prompt()，若从 Stage1 重训，新数据集将自动包含该约束。

3.9.3 错误类型系统分析

综合 Baseline 数字与 DIR_RULE 实验结论，表 3.17 对所有失败模式进行系统性归类：

表 3.17 主方法失败类型系统分析

失败类型	发生率	主要场景	根因与可修复性
NO_ANCHOR 漏报	6.11%	val_normal	标注将 relief/normal 标为 NO_ANCHOR，评估却要求识别；Policy A 重标可修复
Strict 格式失败	5.37%	simple_local	100%来自标注-评估口径错配；与 no_anchor_miss 强相关
Changed-edge 未召回	10.7%	全场景	模型对稀疏性过度保守（recall=89.3%），Constrained Beam Search 可部分改善
方向字段错误	<1%	directional	DIR_RULE 推理注入实验证实不是主要失败来源（strict_fail=0.00%）
解析格式失败	0.00%	—	宽松解析 0%；ANCHOR 格式已被模型掌握，非格式层面问题

注：发生率基于 overall 540 条样本统计。*方向错误 <1% 由 directional_asymmetry 场景 strict_fail=0.00%推算，非直接计数。

错误分析的核心结论：当前主方法的主要瓶颈不在于文本生成格式（ parse_fail=0.00% ） 或 复杂场景泛化（ val_special no_anchor_miss=0.00%），而在于训练标注策略与严格评估口径之间的系统性错配。这意味着 Policy A 重标方案能在不改变模型结构和参数的情况下显著提升整体严格指标，是性价比最高的后续改进方向。

3.9.4 GAT 图补全与 RL 基线（探索性）

在正式 6 场景 completion-aware SUMO 协议下， Sparse-LoRA+GAT 作为 Extended / 探索性扩展，其行程时间与主方法完全相同（1257.33 s）， Completion Rate 同为 83.3%， Truncated Runs 同为 1；其主要差异是 signal_ratio 提升至 100.0。覆盖率提升不等同于路径质量提升，完整结果见附录 A2。PPO 在简化 5×5 网格下运行，不可与主表直接对比（附录 A3）。DQN 候选集选择架构的约束率不代表同类能力优势。

3.10 讨论与局限性

3.10.1 已经成立的结论

基于上述实验，可以得到三条较稳的结论。第一，结构化时空增强输入

是有效的，No-SpatioTemporal 消融证明显式注入结构化字段能够显著提高约束遵守率（+17.25 pp）。第二，稀疏语义锚点输出成功解决了小模型在密集长输出任务中的关键瓶颈，抗截断实验提供了最直接的证据（noisy_long 截断率 0%）。第三，completion-aware SUMO 闭环主表显示，主方法在行程时间上与 Rule-A* 基本持平，并通过显式报告 Completion Rate 和 Truncated Runs 避免了把未完成运行误判为真实到达。

3.10.2 主要局限性

(1) simple_local 场景标注—评估口径错配。 51 个 strict 评估失败案例（100%）可追溯到标注策略与评估口径不一致：训练时将 relief/normal 事件标为 NO_ANCHOR，strict 评估却要求识别这些边。已识别修复方案（Policy A 重新标注）因时间约束未在本版中执行，相关结果应谨慎解读。DIR_RULE 实验（3.8.2 节）进一步确认方向错误不是主要失败来源，simple_local 标注错配才是根本瓶颈。

(2) 模型行为在 fine-tune 后固化，推理 hint 无效。 DIR_RULE 注入实验证明，经过 Stage1-3 课程训练后的模型权重已收敛，推理时新增指令对已固化的输出分布无影响，与 Stage4 四次修复实验失败的结论一致。解决问题需从数据层介入（如重训时内嵌 DIR_RULE 到所有样本）。

(3) GAT 图补全未形成稳定收益。 如 3.8.4 节所述，覆盖边+81.4pp 但行程时间 $\pm 0.0s$ ，图补全在当前任务链中不宜作为核心创新。

(4) RL 基线与 SUMO 主协议不匹配。 PPO 等 RL baseline 运行于简化环境，不能与主结果直接比较。

3.11 本章小结

本章系统分析了本文方法的实验表现。主表结果（表 3.5）表明，在 completion-aware 冻结口径下，Sparse-LoRA-v2 平均行程时间为 1257.33 s，与 Rule-A*（1257.12 s）基本持平；其 Completion Rate 为 83.3%，Truncated Runs 为 1。Rule-A* 的路阻系数计算方式已在 2.4.2 节完整说明，确保对比公平性。规划时间分解（表 3.4）表明 1.4229 s 总延迟中 99.98% 来自 LLM 推理，满足出发前规划实时性需求。消融实验（表 3.9）证明结构化时空增强输入带来约束遵守率 17.25 pp 的提升；抗截断实验（表 3.10）展示了稀疏输出格式在 noisy_long 场景中的绝对优势（截断率 0%）；严格评估协议有效揭示了传统 MAE 无法暴露的关键失

败类型。

3.6 节补充验证了 SUMO 交通运行指标（表 3.7/表 3.8），核心发现：stop_count 修复后各方法停车次数 3.83-7.50 次（DQN 最高），延误时间与行程时间相关性接近 1.0，compound_disaster 场景延误占比达 89.7%，验证了行程时间作为主指标的代表性。3.8 节补充了 val_special 场景细分（表 3.11，5 种复杂场景 strict_fail=0.00%）和 val_normal 长度分桶（表 3.12，noisy_long 样本量极小不宜立论），进一步建立了失败模式的全景视图。3.9 节误差分析章节提供了三个层次的贡献：Baseline 完整数字表（表 3.13-表 3.14）建立了精确的性能基准；DIR_RULE 推理注入实验（表 3.15/表 3.16）以全场景 $\pm 0.0pp$ 的结果证明了 fine-tune 后模型行为的固化特性，并通过 directional_asymmetry $\Delta = \pm 0.0pp$ 将方向错误从失败根因中排除；错误类型系统分析（表 3.17）给出了各类失败的根因定位与可修复路径。

第4章 总结与展望

4.1 全文总结

本文围绕城市路网中自然语言动态交通约束如何被小模型稳定解析并用于路径规划这一问题，提出了一个面向实际部署需求的推理优化框架。整体设计收口为：结构化时空输入 + 稀疏语义锚点输出 + 经典搜索 + 严格评估 + SUMO 闭环。这种设计的关键不在于更大的模型或更复杂的网络结构，而在于通过中间表示和评估协议的重新设计，使小模型能够在复杂约束理解任务中获得更高的稳定性与可解释性。

在三个主要贡献层面，实验均提供了直接的量化证据：结构化时空输入消融证明了字段注入的必要性（+6.1%行程时间，+17.25 pp 约束率）；抗截断实验证明了稀疏锚点解决了全量输出的根本性失稳问题（noisy_long 截断率从 100%降至 0%）；completion-aware SUMO 闭环主表证明了小模型在合理任务重构后可达到与规则基线接近的闭环行程时间，并能通过完成状态审计避免截断误读。

上述结论表明，本文的主要方法价值并不在用 LLM 取代经典搜索，而在让 LLM 提供更可靠的约束感知，再由经典搜索完成最优路径求解。这种混合式框架与 LLM-A*所体现的研究趋势相一致[7]：利用 LLM 的高层语义理解能力，同时保留经典搜索在局部最优性和可验证性上的优势。

4.2 后续工作展望

方向 1：针对 simple_local 场景的标注策略修订（Policy A）与针对性重训，预期使 strict 通过率提升约 17 个百分点，实现 simple_local 指标的正面展示。同时，DIR_RULE 已内嵌至 format_sparse_prompt()的数据生成层，从 Stage1 全量重训（约 8 小时）后方向字段准确率预期进一步提升，无需额外实验设计。

方向 2：引入受限解码（constrained decoding）或 schema 约束机制[9][11]，使稀疏锚点输出进一步标准化，减少解析歧义。SoEval[17]和 SLOT[11]的评估结果表明，小模型在合适的输出约束下可以达到较高 schema 可靠性，为这一方向提供了理论支撑。

方向 3：在图模块方向，将固定补全发展为自适应依赖图学习，借鉴 Graph WaveNet[5]和 AGCRN[6]对隐式依赖矩阵的建模思路，同时参考

Conformal GNN 框架[19]在可信性建模上的设计，探索何时需要拓扑补全的自适应判断机制。

方向 4：设计旧评估 vs.strict 评估的正式对照实验，为交通 LLM 评估领域提供更通用的方法论参考。

方向 5：将当前框架扩展至真实城市路网（如 OSM 数据），验证稀疏锚点设计在更大规模路网上的泛化能力。同时，可采用更大参数量基础模型配合主动学习采样，突破当前 1.5B 模型容量边界对课程学习的限制[20]。

方向 6：本文已在 3.6 节补充了 SUMO 原生交通运行指标（time_loss、waiting_time、stop_count）的验证分析。主要发现：stop_count 修复后，各方法停车次数为 3.83-7.50 次/6 场景，延误时间与行程时间高度相关（相关系数接近 1.0），延误占比随场景严重程度单调递增（20.2%→89.7%）。后续工作可在更大规模路网和更多场景上复现这一规律，并探索延误时间作为约束优化目标的可行性。

参考文献

- [1] Hart P E, Nilsson N J, Raphael B. A formal basis for the heuristic determination of minimum cost paths[J]. IEEE Transactions on Systems Science and Cybernetics, 1968, 4(2): 100-107.
- [2] Veličković P, Cucurull G, Casanova A, et al. Graph Attention Networks[EB/OL]. arXiv:1710.10903, 2017.
- [3] Li Y, Yu R, Shahabi C, et al. Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting[C]//International Conference on Learning Representations. 2018.
- [4] Yu B, Yin H, Zhu Z. Spatio-Temporal Graph Convolutional Networks: A Deep Learning Framework for Traffic Forecasting[C]//Proceedings of IJCAI. 2018: 3634-3640.
- [5] Wu Z, Pan S, Long G, et al. Graph WaveNet for Deep Spatial-Temporal Graph Modeling[EB/OL]. arXiv:1906.00121, 2019.
- [6] Bai L, Yao L, Li C, et al. Adaptive Graph Convolutional Recurrent Network for Traffic Forecasting[EB/OL]. arXiv:2007.02842, 2020.
- [7] Meng S, Wang Y, Yang C F, et al. LLM-A*: Large Language Model Enhanced Incremental Heuristic Search on Path Planning[C]//Findings of EMNLP 2024. 2024: 1087-1102.
- [8] Wei J, Wang X, Schuurmans D, et al. Chain-of-Thought Prompting Elicits Reasoning in Large Language Models[EB/OL]. arXiv:2201.11903, 2022.
- [9] Scholak T, Schucher N, Bahdanau D. PICARD: Parsing Incrementally for Constrained Auto-Regressive Decoding from Language Models[C]//Proceedings of EMNLP. 2021: 9895-9901.
- [10] Geng S, Cooper H, Moskal M, et al. Generating Structured Outputs from Language Models: Benchmark and Studies[EB/OL]. arXiv:2501.10868, 2025.
- [11] Wang D Y B, Shen Z, Mishra S S, et al. SLOT: Structuring the Output of Large Language Models[EB/OL]. arXiv:2505.04016, 2025.
- [12] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.
- [13] Schulman J, Wolski F, Dhariwal P, et al. Proximal Policy Optimization Algorithms[EB/OL]. arXiv:1707.06347, 2017.
- [14] Hu E J, Shen Y, Wallis P, et al. LoRA: Low-Rank Adaptation of Large Language Models[EB/OL]. arXiv:2106.09685, 2021.
- [15] Lopez P A, Behrisch M, Bieker-Walz L, et al. Microscopic Traffic Simulation using SUMO[C]//2018 21st IEEE International Conference on Intelligent Transportation Systems. 2018: 2575-2582.
- [16] Liu C, Yang S, Xu D, et al. Spatial-Temporal Large Language Model for Traffic Prediction[C]//2024 IEEE International Conference on Mobile Data Management. 2024: 171-180.
- [17] Guo Z, Jin R, Liu C, et al. Evaluating Large Language Models on Structured Outputs: A Systematic Study[J]. Information Processing & Management, 2024, 61(6): 103817.

[18] Meng S, Liu Z, Suris D, et al. Can LLMs Plan Paths with Spatial Constraints?[EB/OL]. arXiv:2408.07639, 2024.

[19] Khani F, Nikolic J, Kjaer M, et al. Urban Traffic Forecasting with Integrated Travel Time and Data Availability in a Conformal Graph Neural Network Framework[J]. Transportation Research Part C, 2024, 166: 104757.

[20] Bengio Y, Louradour J, Collobert R, et al. Curriculum Learning[C]//Proceedings of the 26th Annual International Conference on Machine Learning. 2009: 41-48.

附录

附录 A1 Qwen-LoRA 与 R1-LoRA 消融场景结果

Qwen-LoRA 和 R1-LoRA 在消融场景（A-F，旧协议）下的结果如表 A1 所示。受限于推理延迟及协议差异，未纳入主表重跑，不可与表 3.1 结果直接比较。

表 A1 Qwen-LoRA / R1-LoRA 消融场景对比（旧协议均值，不可与主表直接比较）

方法	行程时间(s)	约束遵守率(%)	推理延迟(s)
Qwen-LoRA	591.95	47.42	15.86
R1-LoRA	785.65	32.18	31.49
Sparse-LoRA-v2（参考）	511.15	68.23	1.42

附录 A2 GAT 图补全探索性实验详细结果

GAT 模块的设计初衷是将 LLM 实际预测覆盖的稀疏边（约占全网 9.4%）通过图注意力网络扩展至更广范围（90.8%，提升+81.4 个百分点），从而弥补稀疏锚点在邻近路段上的盲区。具体实现了两种变体：Always-GAT 采用固定比例混合（ $0.62 \times \text{LLM} + 0.38 \times \text{GAT}$ ），Gated-GAT 根据解析置信度（parse_confidence）自适应调节混合权重。

然而，根据正式 6 场景 completion-aware SUMO 协议验证结果，Sparse-LoRA+GAT（Extended / 探索性扩展）的行程时间与 Sparse-LoRA-v2 完全相同（均为 1257.33 s），Completion Rate 同为 83.3%，Truncated Runs 同为 1，仅 signal_ratio 指标提升至 100.0。这说明：在当前任务链中，提升路段覆盖率本身并不等同于提升路径规划质量，图补全的有效性取决于语义解析质量，而非覆盖范围

compound_disaster 场景下观察到 GAT 的边际改善，但无法在全场景稳定复现，不构成足够强度的实验证据。

附录 A3 RL 基线覆盖性说明

PPO 和 DQN 基线在简化 5×5 网格环境中运行，行程时间量级（约 11 s）与 SUMO 主实验（约 1100-1450 s）差异极大，因此其结果不可与主表直接对比，仅作为方法谱系覆盖参考。DQN-RouteSelector 在 SUMO 协议下运行，但其从 A*候选集中选择路由的特殊架构导致约束遵守率偏高（94.59%），属于架构特性。

附录 A4 simple_local 场景严格评估失败分析

simple_local 场景中共有 51 个 strict 评估失败案例，100%可追溯到标注策略与评估口径错配：

- （1）no_anchor 类（29 件，56.9%）：训练标注将 relief/normal 事件标为 NO_ANCHOR，strict 评估却要求识别这些边；
- （2）changed_edge_miss 类（22 件，43.1%）：anomaly_plus_normal 模式中，正常侧面事件未被标注；
- （3）parse_fail / target_miss（0 件）：无解析失败，说明问题完全在标注策略层面。

已识别的修复方案（Policy A：对 relief/normal 事件重新标注并重训 SFT）预期可使 strict 通过率提升约 17 个百分点，因时间约束未在本版中执行，留待后续研究。

附录 A5 Stage4 定向修复迭代失败记录

在 Sparse-LoRA-v2（stage4_fix）冻结后，本文进行了四轮定向修复实验试图通过补充合成数据解决 Stage3 遗留的局部失败案例。表 A5 记录了各次迭代的量化结果：

表 A5 Stage4 定向修复迭代失败明细

迭代	目标改变边数	实际有效改变	误报数	结论
Stage4	—	轻微改善	—	触发上游冻结决策
Stage4b_fix	29	0 / 29	0	无学习信号，数据分布偏移
Stage4c_fix	28	1 / 28	8	严重过拟合，泛化性丧失
Stage4d_micro	18	0 / 18	8	彻底失效，模型容量已达上限

注：目标改变边数指本次修复实验希望模型学会识别的新增边数；实际有效改变指验证集上真正改善的边数；误报数指原本正确识别的边被错误改变的数量。

四次迭代的失败规律高度一致，表明根本原因不在于数据质量，而在于 1.5B 参数量的基础模型在经历 Stage1-3 课程训练后已达容量边界[20]。后续工作建议采用更大参数量模型（如 Qwen 7B 或 DeepSeek-R1 7B）并配合主动学习采样策略，通过验证器模型筛选 Stage4 合成数据以避免分布偏移。

附录 A6 Runtime Metrics Audit

A6.1 stop_count 修复

stop_count 不再读取当前 SUMO 输出中不存在的 tripinfo.stopCount 字段，而是根据采样车辆轨迹中的 speed transition 统计。当 last_speed ≥ 0.1 m/s 且当前 speed < 0.1 m/s 时，计一次 stop。

A6.2 unfinished trip 修复

对于 arrival = -1 或 vaporized = end 的记录，不再标记为 arrived。scene-level metrics 中保留 vehicle_arrived、simulation_truncated 和 completion_status 字段；travel_time_s 接近 evaluation horizon 的记录不再被静默当作真实到达，而作为 truncated/incomplete runs 呈现。

A6.3 当前冻结 run 与一致性检查

当前冻结目录：/root/autodl-tmp/results/
final_frozen_20260424_completion_aware。completion_status 分布为 arrived=29、truncated_at_evaluation_end=7；scene-level metrics 总数为

36，positive_wait_zero_stop=0，simulation_truncated=true 为 7。

A6.4 Truncated Runs by method

Dijkstra: 1；Rule-A*: 0；DQN: 3；GCN-Weight: 1；Sparse-LoRA: 1；Sparse-LoRA+GAT: 1。

表 A6 Truncated runs audit (n=7)

Scenario	Method	Travel Time	Time Loss	Waiting Time	Stops	Completion Status	arrival	vaporized	Eval End
场景 D 中央核心节点封锁	Dijkstra	2160.1	1815.6	1800.6	6	truncated_at_evaluation_end	-1.0		2400
场景 D 中央核心节点封锁	DQN	2160.1	1786.8	1768.1	6	truncated_at_evaluation_end	-1.0	end	2400
场景 G 传播范围外溢	DQN	2160.1	1808.9	1790.2	6	truncated_at_evaluation_end	-1.0	end	2400
场景 C 多路段复合拥堵	DQN	2400.1	2004.8	1981.0	7	truncated_at_evaluation_end	-1.0	end	2700
场景 G 传播范围外溢	GCN-Weight	2160.1	1879.3	1861.8	7	truncated_at_evaluation_end	-1.0	end	2400
场景 C 多路段复合拥堵	Sparse-LoRA	2400.1	2152.5	2113.2	9	truncated_at_evaluation_end	-1.0	end	2700
场景 C 多路段复合拥堵	Sparse-LoRA+GAT	2400.1	2152.5	2113.2	9	truncated_at_evaluation_end	-1.0	end	2700

注：完整审计文件见 runtime_metrics_audit.md 和 truncated_runs_audit.csv；上表仅保留截断审计的关键字段，protocol_snapshot_json 等长字段保留在 CSV 资产中。

攻读学位期间学术论文和科研成果目录

（此处填写攻读学位期间发表或完成的学术论文、专利、项目等，按学

校要求格式填写。)

致 谢

(此处填写致谢内容。)